Modélisation d'un générateur PV avec Commande MPPT pilotée par un Réseau de Neurones.

1 Modélisation Mathématique du Panneau PV

Le panneau est modélisé à l'aide du modèle standard à une diode, représenté par l'équation suivant :

$$I_{\text{pv}} = I_{\text{ph}} - I_{\text{rs}} \left[\exp\left(\frac{q\, V_{\text{pv}}}{p\, k\, T_k\, n_s} \right) - 1 \right] \tag{1}$$

où $q = 1{,}602 \times 10^{-19}\,\text{C}$ est la charge élémentaire, $k = 1{,}38 \times 10^{-23}\,\text{J K}^{-1}$ la constante de Boltzmann, $n_s = 36$ le nombre de cellules en série, $p = 1.3$ le facteur d'idéalité de la jonction, et T_k la température absolue en Kelvin.

Le photocourant I_{ph} et le courant de saturation inverse I_{rs} sont asservis aux conditions environnementales réelles :

$$I_{\text{ph}} = [I_{\text{sc}} + \alpha(T_k - T_{\text{ref}})] \cdot \frac{G}{1000} \tag{2}$$

$$I_{\text{rs}} = I_r \left(\frac{T_k}{T_{\text{ref}}} \right)^3 \exp\left[\frac{q\, E_g}{p\, k} \left(\frac{1}{T_{\text{ref}}} - \frac{1}{T_k} \right) \right] \tag{3}$$

Solveur Numérique : La méthode de Newton-Raphson est implémentés pour calculer le courant I_{pv} à chaque étapes de temps. Pour chaque tension $V_pv(idx)$, I_{pv} est obtenue par itération :

$$I^{(k+1)} = I^{(k)} - \frac{f(I^{(k)})}{f'(I^{(k)})}, \quad \text{avec } f'(I) = 1 \tag{4}$$

Le Solveur stop lorsque $|\Delta I| > 10^{-8}$, les courbes I - V et P - V nous permet de localiser le maximum power point :

$$P_{\max} = \max(V_{\text{pv}} \times I_{\text{pv}}) \implies (V_{\text{mpp}}, I_{\text{mpp}}) \tag{5}$$

Pour simplifier le calcul numérique on prend $R_{shunt} = 0$

2 Convertisseur DC-DC Boost

Pour transférer la puissance maximale vers une charge résistive R_L, un hacheur élévateur (Boost) est inséré entre le générateur PV et la charge.

En régime de conduction continue (CCM), la relation de transfert de tension idéale est :

$$V_{\text{load}} = \frac{V_{\text{pv}}}{1 - D} \tag{6}$$

En négligeant les pertes du convertisseur ($P_{\text{in}} \approx P_{\text{out}}$), l'impédance d'entrée équivalente R_{in} vue par le panneau solaire s'exprime en fonction de la résistance de charge R_L et du rapport cyclique $D \in [0, 1[$:

$$R_{\text{in}} = (1 - D)^2 R_L \tag{7}$$

Pour contraindre le panneau à opérer exactement à son point de puissance maximale, l'impédance d'entrée doit égaler l'impédance interne optimale du panneau $R_{\text{in,mpp}} = \frac{V_{\text{mpp}}}{I_{\text{mpp}}}$. On en déduit analytiquement la loi de commande optimale :

$$D_{\text{mpp}} = 1 - \sqrt{\frac{R_{\text{in,mpp}}}{R_L}} = 1 - \sqrt{\frac{V_{\text{mpp}}}{I_{\text{mpp}} \cdot R_L}} \tag{8}$$

Cette relation analytique fournit la consigne idéale de rapport cyclique servant de vérité terrain pour l'entraînement du réseau neuronal.

3 Réseau de Neurones (FFNN)

3.1 Constitution de la Base de Données d'Apprentissage

Le modéle mathématique développés sous MATLAB fait un balayage couvrant l'ensemble du domaine d'exploitation :

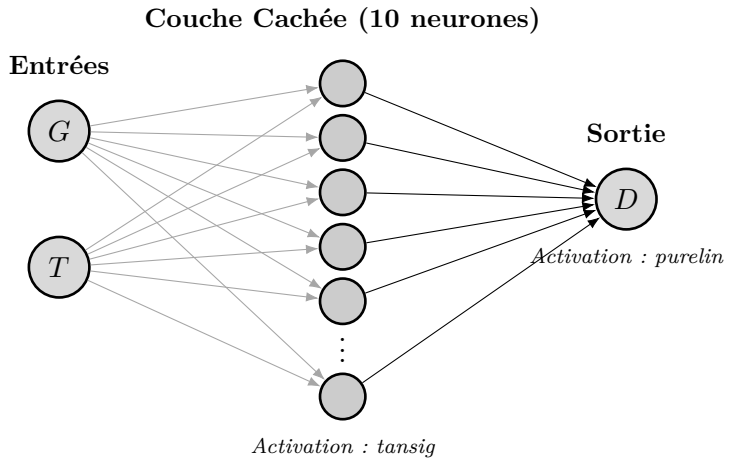
— Ensoleillement $G \in [100, 1000]\,\text{W m}^{-2}$ avec un pas de $50\,\text{W m}^{-2}$.

— Température $T \in [15, 65]\,^{\circ}\text{C}$ avec un pas de $5\,^{\circ}\text{C}$.

Pour chaque pair (G,T), la puissance maximale et le rapport cyclique sont calculés via l'équation 8. L'ensemble de données généré comporte 209 échantillons.

3.2 Architecture et Topologie du Réseau

Le réseau choisi est un Perceptron Multicouche (MLP) à propagation avant (*Feedforward*) :



— **Couche d'entrée :** Irradiance G et Température T.

— **Couche cachée :** fonction d'activation tangente sigmoide.

— **Couche de sortie :** Rapport cyclique $D \in [0.05, 0.85]$ avec fonction linéaire (purelin).

3.3 Optimisation et Validation

L'apprentissage est fait via l'algorithme de **Levenberg-Marquardt** (trainlm) (trés bon choix pour les problèmes d'approximation de fonction). Les données sont reparties comme ceci : 70% apprentissage, 15% validation, 15% test indépendant.

4 Simulink

Le réseau entraîné a été exporté sous Simulink (`gensim`) et interconnecté dans le modèle de puissance complet multiphysique (`circuit_pv.slx`) comprenant le panneau solaire, l'inductance de lissage ($L = 0{,}4\,\mathrm{mH}$), la capacité intermédiaire ($C = 50\,\mu\mathrm{F}$), l'interrupteur MOSFET modulé à une fréquence de découpage $F_{\mathrm{sw}} = 10\,\mathrm{kHz}$, et la charge résistive.

Un profil d'ensoleillement variable en échelons ($500 \rightarrow 1000 \rightarrow 800 \rightarrow 600 \rightarrow 200\,\mathrm{W\,m^{-2}}$) a été appliqué pour confronter le contrôleur neuronal au contrôleur conventionnel à incrément de conductance (InCond).

Analyse des résultats :

1. **Rapidité dynamique :** Le réseau de neurones calcules instantanément par produit matricielle la valeur optimale de D
2. **Robustesse :** Un test a été menée : On applique un ensoleillement étrange sur notre système ($G > 1000\ W\mathrm{m}^{-2}$) on constate que le réseau de neurones gére avec aisance l'Irradiance inconnue (gràce à la fonction tangente sigmoide) et le systéme reste stable en toutes cas.

5 Conclusion et Compétences Développées

Ce projet valide l'efficacité de l'association entre intelligence artificielle et électronique de puissance pour la commande de systèmes énergétiques renouvelables.